

REDES NEURONALES 2022

Clase 3 Parte 1

FRANCISCO TAMARIT Y JUAN PEROTTI

FAMAF, UNIVERSIDAD NACIONAL DE CÓRDOBA

INSTITUTO DE FÍSICA ENRIQUE GAVIOLA (UNC-CONICET)

francisco.tamarit@unc.edu.ar juan.perotti@unc.edu.ar

REDES NEURONALES

2022

Clase 3 Parte 1

Facultad de Matemática, Astronomía, Física
Universidad Nacional de Córdoba

Martes 23 de agosto

<http://www.famaf.unc.edu.ar/~ftamarit/redes2022>

<https://www.famaf.unc.edu.ar/course/view.php?id=981>

APRENDIZAJE AUTOMÁTICO

Decimos que una máquina aprende con respecto a una tarea específica T , una métrica de rendimiento P y un tipo de experiencia E si mejora sustancialmente su rendimiento P para realizar la tarea T a partir de los ejemplos E .

El aprendizaje automático surgió en la frontera entre las Ciencias de la Computación y la Estadística:

- La ciencia de la computación se pregunta cómo construir máquinas capaces aprender automáticamente a resolver problemas y cuales problemas son tratables.
- La estadística se ocupa de estudiar qué se puede inferir de un conjunto de datos a los cuales agregamos un conjunto de suposiciones que modelan el sistema.

La matemática, la física, la ingeniería y la psicología han ayudado notablemente al desarrollo del aprendizaje automático.

LAS TAREAS QUE PUEDE HACER UNA RED NEURONAL

- Reconocimiento de habla
- Generación de textos
- Clasificación y resumen de textos
- Interpretación de textos
- Lectura de labios
- Análisis y clasificación de gestos
- Traducción automática
- Análisis gramatical automático
- Visión por computadora
- Reconocimiento de formas y objetos
- Coloreado y manejo de luminosidad
- Texturización
- Supresión de ruido
- Imitación
- Procesamiento de arte visual
- Recuperación de imágenes
- Predicciones psicológicas

APRENDIZAJE AUTOMÁTICO Y SUS APLICACIONES

COMERCIO ELECTRÓNICO

- Sistemas de recomendaciones
- Comercio minorista
- Publicidad personalizada
- Atención automática de clientes (chatbot)
- Precios dinámicos
- Split testing o A/B
- Realidad aumentada

FINANZAS

- Detección de fraudes
- Puntuación para créditos
- Clasificación de riesgos de seguro
- Prevención y seguimiento de lavado de dinero
- Administración de portfolios
- Trading algorítmico

CYBER SEGURIDAD

- Protección y autenticación de claves
- Detección de ataques y amenazas
- Prevención de sustitución de identidad (phishing)
- Administración de vulnerabilidades

SALUD

- Clasificación de tejidos
- Predicción de enfermedades e identificación de riesgos
- Diagnóstico
- Recomendación de tratamientos
- Descubrimiento de nuevas drogas medicinales
- Prevención de epidemias
- Optimización de procesos hospitalarios

INDUSTRIA

Robótica (neuro control)

- Visión
- Grasping
- Control de movimientos

Conducción automática

Convergencia IT/OT

Gemelos digitales

Mantenimiento predictivo

Calidad y rendimiento predictivo

Logística

SEGURIDAD PÚBLICA Y DEFENSA

MUCHOS MÁS...

APRENDIZAJE AUTOMÁTICO


Clasificación de los algoritmos

- Algoritmos de regresión
- Árboles de decisión
- Algoritmos bayesianos
- Algoritmos de conglomerado
- Algoritmos de reducción de dimensionalidad
- **Redes neuronales**
 - Perceptrons (back propagation)
 - Redes recurrentes (Hopfield)
- **Aprendizaje profundo**
 - Deep Boltzmann Machine
 - Deep Belief Networks
 - Convolutional Neural Networks (CNN)
 - Staked Auto Encoders

APRENDIZAJE AUTOMÁTICO

Tareas usuales

Clasificación



Cat




Dog

APRENDIZAJE AUTOMÁTICO

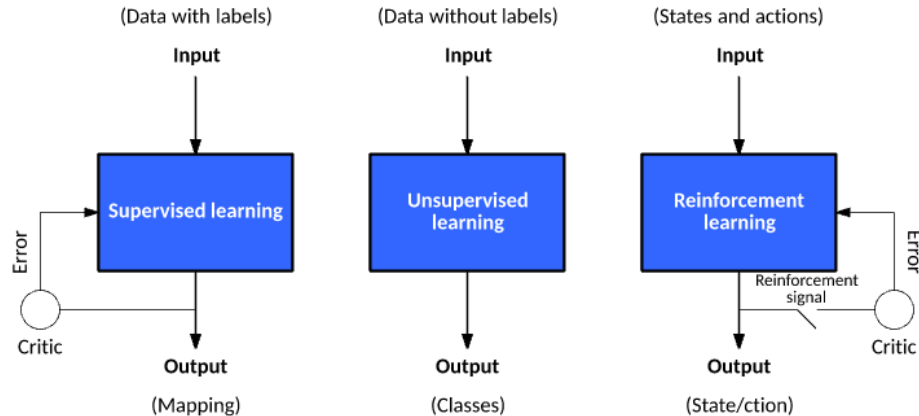
Tareas usuales

Regresión



APRENDIZAJE AUTOMÁTICO

Algoritmos



En el aprendizaje supervisado los datos incluyen las respuestas correctas. Podemos evaluar a medida que el sistema aprende, cuan bien realiza la tarea.

En el aprendizaje no supervisado no se dispone del resultado deseado y el sistema debe segmentar los datos en “clases” adecuadamente.

En el aprendizaje con refuerzo se agrega una recompensa o un castigo para mejorar el proceso, emulando algunas formas de aprendizaje natural.

REDES NEURONALES


El paradigma conexionista

En **conexionismo** asume que el procesamiento y el almacenamiento de la información recae en la compleja arquitectura de conexiones que forman las neuronas entre sí y con otras células, y que las neuronas son simples unidades de procesamiento y transmisión de señales.

REDES NEURONALES

Topologías más comunes

- *Redes feed-forward*



REDES NEURONALES

Topologías más comunes

- *Redes recurrentes*




Figura 8: Arquitectura de una Red de Hopfield

APRENDIZAJE SUPERVISADO

Conexiones sinápticas


El desafío siempre consiste en encontrar todos los números w_{ij} que modelan la eficacia de las sinapsis, y estos deben ser tales que permitan que la red asigne correctamente los patrones de **entrada** con los de **salida** de la actividad que queremos que realice.

Si el aprendizaje es supervisado, conocemos de antemano un conjunto de relaciones **entrada-salida** correctas etiquetadas con la letra μ . De ellas un subconjunto será utilizado primero para entrenar a la red, o sea, buscar el conjunto de sinapsis $\{w_0, w_1, \dots, w_N\}$, y luego el resto se utilizará para evaluar su desempeño.

Si la red funciona bien, entonces resolverá **casi siempre bien** las relaciones entrada-salida a las cuales nunca ha sido presentada previamente.

APRENDIZAJE SUPERVISADO

Feed Forward y back-propagation



$$E = \sum_p E^p = \frac{1}{2} \sum_p (d^p - y^p)^2,$$

$$\Delta_p w_j = -\gamma \frac{\partial E^p}{\partial w_j}$$

Suma sobre el conjunto
de entrenamiento

Salida correcta

Salida obtenida

REDES NEURONALES

Feed Forward y back-propagation

$$E = \sum_p E^p = \frac{1}{2} \sum_p (d^p - y^p)^2,$$

Corregimos todas las sinapsis de forma tal que minimicen el error, descendiendo por el gradiente

$$\Delta_p w_j = -\gamma \frac{\partial E^p}{\partial w_j}$$


REDES NEURONALES

Un ejemplo



0	4	1	9	2	1	3	1	4	3
5	3	6	1	7	2	8	6	9	4
0	9	1	1	2	4	3	2	7	3
8	6	9	0	5	6	0	7	6	1
8	7	9	3	9	8	5	9	3	3
0	7	4	9	8	0	9	4	1	4
4	6	0	4	5	6	1	0	0	1
7	1	6	3	0	2	1	1	7	9
0	2	6	7	8	3	9	0	4	6
7	4	6	8	0	7	8	3	1	5

REDES NEURONALES


Un ejemplo




REDES NEURONALES PARA COMPUTAR FUNCIONES UNIVERSALES



REDES NEURONALES PARA COMPUTAR FUNCIONES UNIVERSALES




REDES NEURONALES PARA COMPUTAR FUNCIONES UNIVERSALES






REDES NEURONALES


Las redes convolucionales como ejemplo de aprendizaje profundo



La evolución de las redes neuronales







En este gráfico vemos cómo aumenta el número de sinapsis (parámetros) que usan las redes neuronales más exitosas. Noten por ejemplo que GPT-3, de Elon Musk, tiene 175.000.000.000 parámetros o sinapsis. O sea, el algoritmo tiene que optimizar y encontrar el mejor juego de este enorme conjunto de parámetros. Noten que el eje x es lineal (a la misma distancia el mismo tiempo), pero el eje y es logarítmico. Esto dice que el número de parámetros crece exponencialmente, con una velocidad muy grande. A fines del siglo XX podíamos entrenar redes con algunos miles de parámetros. La curva no para crecer y crece cada vez más rápido. Tener más sinapsis es lo que necesitamos para resolver problemas más complejos. GPT-3 es un generador automático de artículos de texto (modelo autoregresivo y profundo).